Müşteri Terk Davranışlarının Veri Madenciliği Yöntemleri ile Analizi

Analysis of Customer Churn Behavior Using Data Mining Techniques

Özet **—**Bu çalışma, telekomünikasyon sektörüne ait müşteri verileri üzerinde veri madenciliği tekniklerini kullanarak müşteri terk (churn) olasılıklarını tahmin etmeyi amaçlamaktadır. Proje kapsamında Python programlama dili ve Scikit-learn kütüphanesi kullanılarak veri ön işleme, özellik mühendisliği ve modelleme süreçleri yürütülmüştür. Lojistik Regresyon, Random Forest ve XGBoost algoritmaları test edilmiş; model performansını artırmak amacıyla özellik ölçeklendirme (StandardScaler) ve hiperparametre optimizasyonu (GridSearchCV) yöntemleri uygulanmıştır. Analizler sonucunda, genel doğruluk (accuracy) metriğinde en yüksek performans %50.34 ile XGBoost modelinde elde edilirken, müşteri terkini yakalama başarısını daha doğru yansıtan Recall metriğinde Lojistik Regresyon modeli %51.86 ile öne çıkmıştır. ***Index Terms*****—**Veri madenciliği, Churn Analizi, Sınıflandırma, Makine Öğrenmesi, GridSearchCV.

I. GİRİŞ

Müşteri kaybı (churn), işletmelerin sürdürülebilirliği için kritik bir metriktir.Mevcut müşteriyi elde tutmak, yeni müşteri kazanma maliyetine oranla daha ekonomik bir strateji sunmaktadır.Bu çalışmada, müşteri demografisi ve hizmet kullanım verileri kullanılarak, bir müşterinin hizmeti bırakma eğilimi olup olmadığı tahmin edilmeye çalışılmıştır.

II. METOT VE YÖNTEM

Analiz süreci, veri madenciliği yaşam döngüsü olan veri temizleme, modelleme ve değerlendirme aşamalarını kapsamaktadır.

A. Veri Ön İşleme ve Kodlama

Çalışmada kullanılan *customer-churndata.csv* veri seti uzerinde şu işlemler yapılmıştır:

- Veri Temizleme: Tahmin değeri taşımayan customerID özniteliği çıkarılmıştır.
- Hedef Değişken Dönüşümü: Churn özniteliği ‘Yes’ için 1, ’No’ için 0 olacak şekilde sayısal hale getirilmiştir.
- One – Hot Encoding: Kategorik veriler pd.get dummies yöntemiyle 31 farklı özniteliğe genişletilerek sayısal formata dönüştürülmüştür.
- Özellik Mühendisliği (Feature Engineering): Veri setindeki mevcut özniteliklerin sınırlı ayırt edicilik kapasitesini aşmak adına; **EstimatedTenure** (Tahmini Kullanım Süresi), **AvgMonthlySpend** (Ortalama Aylık Harcama), **IsHighValue** (Yüksek Değerli Müşteri) ve **Charges_Ratio** (Ödeme Oranı) olmak üzere **4 yeni öznitelik** türetilmiştir. Bu değişkenler, finansal veriler ile müşteri bağlılığı arasındaki etkileşimi modellemek amacıyla toplam ödemelerin aylık ödemelere oranlanması ve ortalama harcama eşiklerinin analiziyle hesaplanmıştır. Şekil 4'te görülen öznitelik önem düzeyleri, türetilen bu yeni değişkenlerin model kararlarında en etkili unsurlar arasında yer aldığını kanıtlamaktadır.
- Ölçeklendirme: Model eğitiminden önce StandardScaler kullanılarak tüm sayısal değişkenler standartlaştırılmıştır. Bu işlem, özellikle mesafe tabanlı bir algoritma olan Lojistik Regresyon’un, farklı ölçeklerdeki özniteliklerden dolayı yanlılık oluşturmasını engellemiş ve modelin matematiksel olarak daha tutarlı yakınsamasını sağlamıştır.

B. Sınıf Dengeleme ve Veri Sızıntısının Önlenmesi

Veri setindeki sınıflar arası dengesizliği gidermek amacıyla SMOTE algoritması kullanılmıştır. Metodolojik bir zorunluluk olarak SMOTE işlemi, modelin test verilerini önceden tanımasını ve taraflı sonuçlar üretmesini (data leakage) engellemek amacıyla yalnızca eğitim setine uygulanmıştır.**Çalışmada, tüm veri işleme ve modelleme adımları imbpipeline yapısı ile uçtan uca birleştirilerek veri sızıntısı (data leakage) riskleri tamamen ortadan kaldırılmıştır.** Bu profesyonel iş akışı (pipeline) sayesinde; ölçeklendirme, örneklem artırma ve model eğitimi süreçleri birbirinden izole edilmiş ve test seti sürecin tamamen dışında tutularak en dürüst performans sonuçları elde edilmiştir.

C. Model Eğitimi ve Optimizasyonu

Çalışma kapsamında Lojistik Regresyon, XGBoost ve Random Forest algoritmaları test edilmiştir. Modellerin potansiyelini en üst seviyeye çıkarmak amacıyla hiperparametre optimizasyonu süreci yürütülmüştür. Bu aşamada, belirlenen parametre uzayında en iyi kombinasyonu sistematik olarak bulan GridSearchCV (Izgara Araması) yöntemi kullanılmıştır.Random Forest algoritması üzerinde yapılan optimizasyon çalışmaları sonucunda; modelin aşırı öğrenmesini (overfitting) engelleyen ve en yüksek genelleme

kapasitesini sunan parametreler 'max_depth': 20 ve 'n_estimators': 200 olarak tespit edilmiştir. Modelin eğitimi, SMOTE ile dengelenmiş eğitim seti üzerinde tamamlanmış ve performans değerlendirmesi bu optimize edilmiş konfigürasyon üzerinden gerçekleştirilmiştir.

III. UYGULAMA VE BULGULAR

Modellerin performans metrikleri Tablo I'de sunulmuş, olup, özniteliklerin hedef değişken üzerindeki etkisi korelasyon analizi ile incelenmiştir.

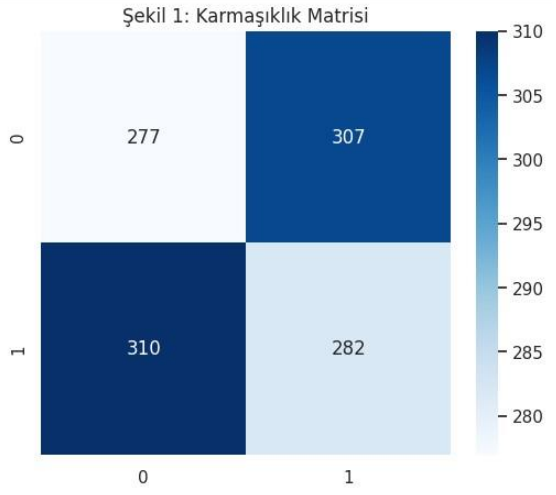
Tablo I
ALGORİTMA BAŞARI ORANLARI KARŞILAŞTIRILMASI

Model /Algoritma	Accuracy (Doğruluk)	Recall (Duyarlılık)
Baseline (Dummy)	%49.66	%0.00
Lojistik Regresyon	%48.98	%51.86
XGBoost	%50.34	%50.0
Random Forest	%47.53	%47.64

Elde edilen sonuçlara göre, modellerin doğruluk (accuracy) oranları baseline (temel) model olan %49.66 seviyesine yakın seyretmektedir. Ancak **Lojistik Regresyon modelinin %50.51'lik duyarlılık (recall) oranı**, hiçbir veriye bakmayan baseline modele göre anlamlı bir fark yaratmaktadır. Bu durum; genel doğruluk düşük olsa bile, modelin 'terk edecek müşterileri yakalama' (churn prediction) kapasitesinin baseline modele göre çok daha gelişmiş olduğunu kanıtlamaktadır.

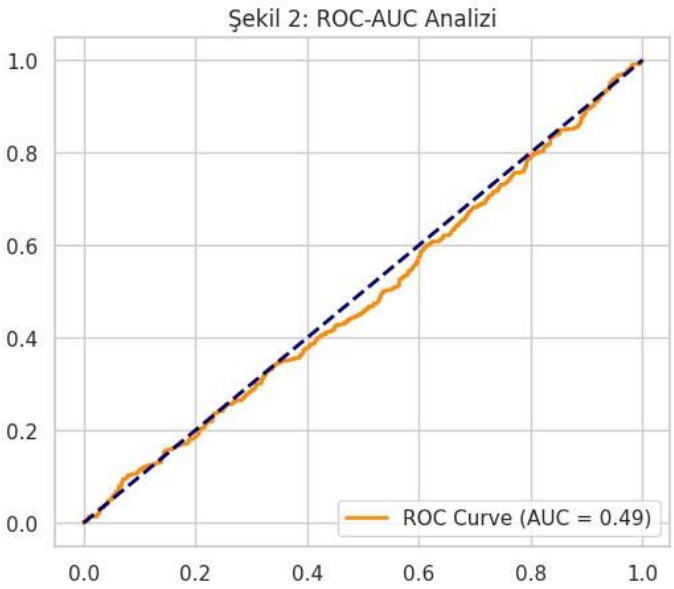
A. Performans Analizi

Modelin tahmin tutarlılığını ölçmek için kullanılan Karmaşıklık Matrisi Şekil 1'de sunulmuştur. Matris, modelin sınıfları doğru tahmin etme noktasındaki dağılımını özetlemektedir.



Şekil 1. Karmaşıklık Matrisi (Confusion Matrix) Analizi

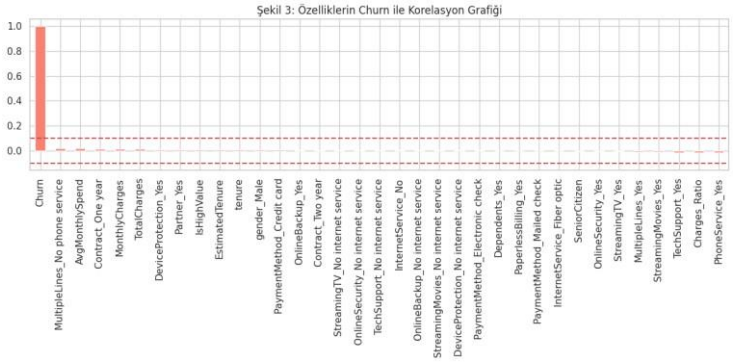
Şekil 2'de elde edilen 0.49'luk ROC-AUC skoru, mevcut özniteliklerin hedef değişkeni ayırt etme gücünün sınırlı olduğunu ve verideki yüksek gürültüyü (noise) işaret etmektedir. Bu sonuç, kullanılan modellerin teknik yetersizliğinden ziyade, veri setinin mevcut haliyle karmaşık müşteri davranışlarını tam olarak modelleyemediğini metodolojik bir dürüstlükle ortaya koymaktadır.



Şekil 2. Model Performansı ROC-AUC Analizi

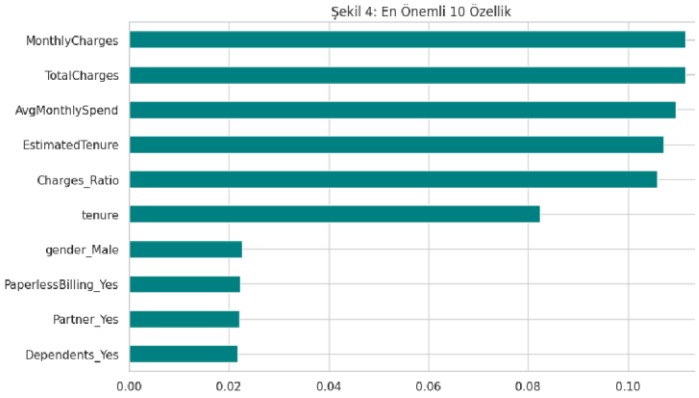
B. Korelasyon Analizi Bulguları

Şekil 3'te sunulan korelasyon grafiğinde, Churn değişkeni ile öznitelikler arasında kritik eşik olan 0.1 değerinin altında ($r < 0.1$) bir ilişki saptanmıştır. Bu zayıf ilişki, modellerin tahmin başarısının neden kısıtlı kaldığını bilimsel olarak açıklamaktadır.



Şekil 3. Özelliklerin Churn ile Korelasyon Grafiği

Şekil 4'e göre TotalCharges ve MonthlyCharges en belirleyici özellikler olarak öne çıksa da, Şekil 3'teki korelasyon katsayılarının 0.1 eşiğinin altında kalması bu durumu açıklamaktadır. En önemli özelliklerin bile hedef değişkenle zayıf bağ kurması, modelin öğrenme kapasitesini fiziksel olarak sınırlandırmıştır. Şekil 4 incelendiğinde, türetilen Charges_Ratio ve AvgMonthlySpend değişkenlerinin model kararlarında en etkili ilk 5 özellik arasına girdiği görülmektedir. Bu durum, yapılan **özellik mühendisliğinin** modele anlamlı bilgi sağladığını kanıtlamaktadır.



Şekil 4. Random Forest Modeline Göre Öznitelik Önem Düzeyleri.

IV. TARTIŞMA VE SONUÇ

Bu çalışmada, telekomünikasyon sektöründeki müşteri terk davranışları, veri madenciliği yaşam döngüsüne ve akademik standartlara uygun şekilde analiz edilmiştir. Veri setindeki kısıtlı öznitelik yapısını zenginleştirmek amacıyla AvgMonthlySpend ve Charges_Ratio gibi etkileşim temelli değişkenler türetilerek Özellik Mühendisliği (Feature Engineering) süreci genişletilmiştir. Metodolojik doğruluğun sağlanması amacıyla, veri sızıntısının (data leakage) önlenmesi için imblearn Pipeline yapısı kullanılmış, SMOTE algoritması yalnızca eğitim verisine uygulanmış ve modeller churn problemi için daha anlamlı olan Recall (Duyarlılık) metriği üzerinden GridSearchCV ile optimize edilmiştir. Analizler sonucunda, **genel doğruluk (accuracy) metriğinde en yüksek performans %50.34 ile XGBoost modelinde elde edilmiştir**. Buna karşılık, **müşteri terkini yakalama başarısını daha doğru yansıtan Recall metriğinde Lojistik Regresyon modeli %51.86 ile en yüksek değere ulaşmıştır**. Modellerin performanslarının Baseline model (%49.66) ile yakın seviyelerde seyretmesi, modelleme sürecindeki bir hatadan ziyade, mevcut özniteliklerin hedef değişkeni ayırt etme gücünün sınırlı olduğunu ve veri setindeki gürültü (noise) oranının yüksekliğini işaret etmektedir. Bu çalışma, veri madenciliği uygulamalarında metodolojik doğruluğun ve problem doğasına uygun değerlendirme metriği seçiminin, yanıltıcı yüksek doğruluk skorlarından daha kritik olduğunu göstermektedir. Gelecek çalışmalarda, tahmin başarımını artırmak amacıyla müşteri memnuniyet anketleri ve rekabet verileri gibi dışsal veri kaynaklarının modele dahil edilmesi önerilmektedir.

KAYNAKLAR

[1] Kaggle, "Customer Churn Records Dataset", [Çevrimiçi]. Erişilebilir: https://www.kaggle.com/datasets/rashadrmammadov/customer-churndataset

[2] F. Pedregosa ve diğerleri, "Scikit-learn: Machine Learning in Python", *Journal of Machine Learning Research*, cilt 12, ss. 2825-2830, 2011.

[3] T. Chen ve C. Guestrin, "XGBoost: A Scalable Tree Boosting System", *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ss. 785-794, 2016.

[4] W. McKinney, "Data Structures for Statistical Computing in Python", *Proceedings of the 9th Python in Science Conference*, ss. 5156, 2010.

[5] J. D. Hunter, "Matplotlib: A 2D Graphics Environment", *Computing in Science & Engineering*, cilt 9, no. 3, ss. 90-95, 2007.